

GMP 문서 구조화 및 검색 평가 최종 보고서

GMP 가이드ンス PDF를 계층형 tree로 구조화하고, tree 기반 검색 흐름이 100개 평가셋에서 정답 근거 page를 얼마나 잘 찾는지 검증했습니다. 공식 headline 성능은 **96.0%**입니다.

대상 문서

gmp_guidance.pdf

보고서 상태

PASS

생성 시각

**2026-06-
25T13:07:20.125537+00:00**

공식 HIT RATE

96.0%

*Aligned predicted
union*

EVAL 문항

100

100개 평가셋

TREE NODES

641

606 pages

UNRECOVERED

1

gmp_eval_025

원문 GMP PDF 열기

보고서와 같은 repository에 포함된 원문 PDF입니다.

Repository: <https://github.com/Dongmin103/docmind-gmp-pageindex-report>

목차

- | | |
|-------|-------------------|
| 1. 배경 | 6. 한계 |
| 2. 요약 | 7. 다음 단계 |
| 3. 방법 | 8. 재현 가능한 산출물 |
| 4. 결과 | 9. 부록 A. Tree 요약 |
| 5. 해석 | 10. 부록 B. Eval 샘플 |

1. 배경

기준 레포: 본 실험은 VectifyAI의 `PageIndex` repository 구조를 기준으로 GMP PDF를 구조화하고 검색 평가까지 확장한 작업입니다.

왜 PageIndex를 기준으로 삼았나? GMP 가이드런스처럼 길고 계층이 깊은 규제 문서는 단순 키워드 검색만으로는 원하는 근거 page를 안정적으로 찾기 어렵습니다. 질문은 보통 특정 단어 하나가 아니라 "어느 장/절의 어떤 기준을 확인해야 하는가"에 가깝기 때문에, 문서를 page 단위 텍스트 더미가 아니라 **section tree + page range**로 다루는 방식이 필요했습니다.

PageIndex는 PDF를 page content와 document structure로 분리해 다루는 흐름을 제공합니다. 이 보고서에서는 그 구조를 GMP 문서에 적용하여, 먼저 목차와 본문 heading을 기반으로 문서 전체를 계층형 tree로 재구성했습니다. 이후 질문별로 `get_document`, `get_document_structure`, `get_page_content` 흐름을 따라 관련 section과 page content를 확인하는 방식으로 검색 성능을 평가했습니다.

구분	내용
기준 repository	VectifyAI/PageIndex
적용 대상	gmp_guidance.pdf
핵심 목적	GMP 문서를 section tree로 구조화하고, 질문이 요구하는 근거 page를 찾을 수 있는지 검증
실험 이유	규제 문서는 제목·장·절·page 범위가 중요하므로 단순 검색보다 구조 기반 검색이 적합한지 확인

2. 요약

핵심 결과: 606 page GMP PDF에서 641개 node의 계층형 tree를 구축했고, 100개 평가셋 기준 공식 aligned hit rate는 **96.0%**입니다.

본 작업은 GMP 문서를 단순 키워드 검색 대상으로 보지 않고, 목차와 본문 heading을 기반으로 section/page 범위가 보존된 tree로 재구성했습니다. 이후 질문별로 tree와 page content를 탐색해 정답 근거 page를 찾는 retrieval 평가를 수행했습니다.

항목	결과	의미
PDF page 수	606	전체 문서 범위
Tree node 수	641	최종 계층 구조 규모
Eval 문항 수	100	검색 평가셋
공식 hit rate	96.0%	최종 선택 page + alignment 보정 기준
Evidence+aligned	99.0%	탐색 과정 coverage 진단 지표

3. 방법

01

PDF 구조화

GMP PDF를 PageIndex workspace로 변환해 page content와 초기 structure를 생성했습니다.

02

Tree 확장/보정

TOC와 본문 heading을 기준으로 모든 주요 branch를 세분화하고 page span을 정규화했습니다.

03

Page alignment

PDF 물리 page와 문서 내부 page 번호가 밀리는 문제를 audit하고 alignment map을 만들었습니다.

04

100문항 eval

질문별 gold page/section path와 predicted page를 비교해 official score를 계산했습니다.

평가 흐름: get_document → get_document_structure → get_page_content 흐름을 기준으로, tree를 보고 관련 section 후보를 고른 뒤 page content를 열어 최종 predicted page를 결정하는 방식입니다.

Tree 생성 예시

처음 PDF에서 현재의 **workspace/tree**까지 온 흐름은 아래와 같습니다. 핵심은 PDF 원문을 바로 검색하는 것이 아니라, 먼저 page별 text와 목차 정보를 이용해 문서 구조를 만들고, 그 구조를 PageIndex workspace 안에 `structure + pages` 형태로 포장했다는 점입니다.

전체 흐름

```
GMP PDF
→ page별 text 추출
→ TOC/목차 page 탐지
→ 목차를 JSON tree 후보로 변환
→ 각 section title이 실제 본문 어느 page에서 시작하는지 매핑
→ node_id, own range, subtree range 보정
→ results/gmp_guidance_structure.json 저장
→ PageIndex workspace/gmp-guidance.json에 structure + pages로 포장
```

1. 입력 PDF

처음 입력은 `inputs/gmp_guidance.pdf` 입니다. 실행 스크립트는 `run_gmp_pageindex.sh` 이고, 그 안에서 실제로는 PageIndex 파이프라인인 `run_pageindex.py` 를 호출합니다.

```
python run_pageindex.py --pdf_path inputs/gmp_guidance.pdf --model gpt-4o-mini --toc-check-  
pages 30 --max-pages-per-node 10 --max-tokens-per-node 20000 --if-add-node-id yes
```

2. PDF를 page별 text로 분리

PDF를 먼저 page 단위로 읽습니다. 그 결과 workspace 안에는 page 번호와 해당 page의 본문이 함께 저장됩니다. 본 GMP 문서는 총 **606 pages**입니다.

```
{  
  "pages": [  
    {  
      "page": 1,  
      "content": "완제의약품제조및품질관리기준가이드스..."  
    },  
    {  
      "page": 2,  
      "content": "..."  
    }  
  ]  
}
```

3. TOC, 즉 목차 page 탐지

PageIndex는 처음 몇 page를 보면서 해당 page가 목차인지 판단합니다. 관련 함수는 `pageindex/page_index.py` 의 `find_toc_pages(...)`, `toc_detector_single_page(...)` 입니다. 개념적으로는 "이 page가 목차인가?"를 확인하고, yes이면 TOC page 목록에 추가하며, no가 나오면 목차 구간을 종료합니다.

우리 실행에서는 `--toc-check-pages 30` 을 사용했기 때문에, 앞 30 page 안에서 TOC를 찾도록 설정했습니다.

4. TOC를 JSON tree 후보로 변환

목차 text를 찾으면 그 목차를 구조화합니다. 관련 함수는 `toc_extractor(...)`, `toc_transformer(...)` 입니다. 예를 들어 목차가 아래처럼 되어 있으면:

```
제2장 완제의약품 제조 및 품질관리기준  
1. 용어의 정의  
2. 시설 및 환경의 관리  
3. 조직
```

이를 다음과 같은 JSON tree 후보로 변환합니다.

```
[  
  {  
    "title": "제2장 완제의약품 제조 및 품질관리기준",  
    "nodes": [  
      {  
        "title": "용어의 정의",  
        "nodes": []  
      },  
      {  
        "title": "시설 및 환경의 관리",  
        "nodes": []  
      }  
    ]  
  }  
]
```

```
]
}
]
```

5. 각 section이 실제 PDF 몇 page에서 시작하는지 찾음

목차만으로는 구조는 알 수 있지만, 실제 본문 page가 정확히 어디인지 확인해야 합니다. 그래서 PageIndex는 본문 text에 page marker를 붙여 section title이 어느 page에서 시작하는지 확인합니다.

```
<physical_index_18>
2장 완제의약품 제조 및 품질관리기준
1 용어의 정의
...
<physical_index_18>
```

그리고 LLM에게 "이 section title이 이 본문 조각에서 시작하면 `start_index` 를 넣어라"라고 요청합니다. 관련 함수는 `add_page_number_to_toc(...)` 입니다. 결과적으로 node에는 page 정보가 붙습니다.

```
{
  "title": "용어의 정의",
  "start_index": 18,
  "end_index": 28
}
```

6. node id와 page range를 보정

우리 작업에서는 여기서 끝내지 않고 추가 보정을 했습니다. GMP 문서에는 중복 제목이 있고, 같은 page에 parent/child가 함께 나오며, `시설 및 환경의 관리` 처럼 branch가 잘못 중첩될 수 있고, PDF 물리 page와 문서 내부 page 번호가 밀리는 문제도 있었기 때문입니다.

그래서 보정 후 최종 node는 다음과 같은 형태가 되었습니다.

```
{
  "title": "용어의 정의",
  "node_id": "0005",
  "start_index": 18,
  "end_index": 28,
  "own_start_index": 18,
  "own_end_index": 18,
  "subtree_start_index": 18,
  "subtree_end_index": 28,
  "nodes": [...]
}
```

- `own_start/end`: 이 node 자체의 page 범위
- `subtree_start/end`: child node까지 포함한 전체 page 범위

7. 최종 tree JSON 저장

최종 tree는 `results/gmp_guidance_structure.json`에 저장됩니다. 구조는 아래와 같고, `structure` 배열 안의 객체들이 전부 section node입니다.

```
{
  "doc_name": "gmp_guidance.pdf",
  "structure": [...]
}
```

8. PageIndex workspace로 포장

그 다음 검색/retrieve에서 쓰기 위해 workspace 형태로 만들었습니다. 최종 workspace는 `results/pageindex_gmp_workspace/` 입니다.

```
results/pageindex_gmp_workspace/
├── _meta.json
└── gmp-guidance.json
```

`gmp-guidance.json` 안에는 문서 식별 정보, tree 구조, page별 본문이 함께 들어갑니다.

```
{
  "id": "gmp-guidance",
  "type": "pdf",
  "doc_name": "gmp_guidance.pdf",
  "page_count": 606,
  "structure": [...],
  "pages": [...]
}
```

- `structure`: tree/node
- `pages`: page별 본문
- `metadata`: 문서 정보

9. retrieve에서 사용

나중에 retrieve는 이 workspace를 순서대로 읽습니다. 먼저 문서 metadata를 확인하고, 그 다음 tree/node 구조를 확인한 뒤, 필요한 page 본문만 엽니다.

```
get_document()
→ metadata 확인

get_document_structure()
→ structure 배열, 즉 tree/node 확인

get_page_content("18")
→ pages에서 page 18 content 확인
```

핵심 요약

처음 PDF에서 지금 구조까지는 **PDF 원문 → page별 text → TOC 탐지 → TOC를 tree 후보로 변환 → 본문에서 section 시작 page 확인 → node id/range 보정 → 최종 tree JSON 생성 → workspace에 structure + pages로 저장 → retrieve가 metadata → tree → page content 순서로 사용하는 흐름으로 만들어졌습니다.**

생성 단계	처리 내용	산출 예시
1	입력 PDF 지정	inputs/gmp_guidance.pdf
2	PDF page content 추출	606개 page content 생성
3	TOC page 탐지	앞 30 page 범위에서 목차 구간 확인
4	TOC를 JSON tree 후보로 변환	제2장 → 용어의 정의 → 다. “일탈” 같은 계층 후보 생성
5	본문 heading과 page 시작점 매핑	<physical_index_18> marker를 이용해 section 시작 page 확인
6	계층 연결	상위 section의 nodes 배열 안에 하위 section 배치
7	node id와 page span 보정	node_id, own_start/end, subtree_start/end 정규화
8	최종 tree JSON 저장	results/gmp_guidance_structure.json
9	PageIndex workspace 반영	structure와 pages를 results/pageindex_gmp_workspace/gmp-guidance.json에 저장

실행 표면: 원본 PageIndex 실행은 `run_pageindex.py`가 담당하고, 본 GMP 실험에서는

`run_gmp_pageindex.sh`가 `--toc-check-pages 30`, `--if-add-node-id yes` 등의 옵션으로 이를 호출했습니다. 이후 GMP 문서 특성에 맞게 중복 제목, 같은 page parent/child, page span, page alignment를 추가 보정했습니다.

실제 JSON node 예시: 아래 예시는 `용어의 정의` section과 그 하위의 `다. “일탈”` node입니다. retrieve는 이 구조에서 `subtree_start_index/end_index`를 보고 먼저 p.18-28 범위를 후보로 잡고, 하위 node의 p.18을 더 좁은 근거 page로 선택합니다.

```
{
  "title": "용어의 정의",
  "node_id": "0005",
  "start_index": 18,
  "end_index": 28,
  "own_start_index": 18,
  "own_end_index": 18,
  "subtree_start_index": 18,
  "subtree_end_index": 28,
  "nodes": [
    {
      "title": "다. “일탈”이란 제조 또는 품질관리 과정에서 미리 정해진 기준을 벗어나 이루어진 행위를 말한다.",
      "node_id": "0008",
      "start_index": 18,
      "end_index": 18,

```

```

    "own_start_index": 18,
    "own_end_index": 18,
    "subtree_start_index": 18,
    "subtree_end_index": 18,
    "nodes": []
  }
}

```

PageIndex workspace 구성

PageIndex workspace는 원본 PDF를 검색하기 좋은 형태로 변환해 저장한 작업 폴더입니다. 본 실험의 workspace는 `results/pageindex_gmp_workspace/`이며, 문서 목록을 담은 `_meta.json` 과 실제 문서 데이터를 담은 `gmp-guidance.json` 으로 구성됩니다.

파일/영역	역할	실제 내용
<code>_meta.json</code>	workspace 안의 문서 목록과 기본 메타데이터	<code>doc_id</code> : gmp-guidance, <code>type</code> : pdf, <code>page_count</code> : 606
<code>gmp-guidance.json · metadata</code>	문서 식별 정보	<code>id</code> , <code>type</code> , <code>path</code> , <code>doc_name</code> , <code>doc_description</code> , <code>page_count</code>
<code>gmp-guidance.json · structure</code>	section tree	<code>title</code> , <code>node_id</code> , <code>page range</code> , <code>nodes</code> , <code>subtree range</code>
<code>gmp-guidance.json · pages</code>	page별 실제 본문	page 1부터 page 606까지 content 저장

Workspace를 읽는 순서: `get_document()` 는 `metadata`를, `get_document_structure()` 는 `structure` 를, `get_page_content()` 는 `pages` 를 읽습니다. 따라서 retrieve는 같은 `gmp-guidance.json` 안에서 `metadata` → `structure` → `pages` 순서로 필요한 정보만 단계적으로 확인합니다.

```

results/pageindex_gmp_workspace/
├── _meta.json
└── gmp-guidance.json
    ├── metadata: id, type, path, doc_name, page_count
    ├── structure: JSON tree nodes
    └── pages: [{ page, content }, ... 606 pages]

{
  "id": "gmp-guidance",
  "type": "pdf",
  "doc_name": "gmp_guidance.pdf",
  "page_count": 606,
  "structure": [
    {
      "title": "제2장 완제의약품 제조 및 품질관리기준",
      "subtree_start_index": 16,
      "subtree_end_index": 478,
      "nodes": [
        "용어의 정의",
        "시설 및 환경의 관리",
        "...

```

Node 저장 위치

Node는 별도의 파일로 따로 저장되는 것이 아니라, JSON의 `structure` 배열 안에 중첩 객체로 저장됩니다. 즉 section 하나가 node이고, 그 node의 하위 section은 다시 `nodes` 배열 안에 child node로 들어갑니다.

파일	역할	NODE 저장 방식
results/gmp_guidance_structure.json	최종 tree 산출물	structure 배열 안에 전체 node tree 저장
results/pageindex_gmp_workspace/gmp-guidance.json	retrieve가 사용하는 workspace 문서	metadata, structure, pages 중 structure 배열 안에 node 저장

Node 저장 규칙: `structure` 안의 객체 하나가 node입니다. 하위 node는 부모 node의 `nodes` 배열에 들어가며, `"nodes": []` 이면 더 이상 자식이 없는 leaf node입니다.

Retrieve 작동 방식

본 평가에서 retrieve는 PDF 전체를 한 번에 검색하는 방식이 아니라, PageIndex workspace에 저장된 **문서 메타데이터, tree 구조, page content**를 순서대로 확인하는 방식으로 작동합니다. 먼저 문서가 어떤 PDF인지 확인하고, 그 다음 JSON tree에서 질문과 관련된 section path와 page range를 좁힌 뒤, 필요한 page 본문만 열어 근거를 확인합니다.

“트리를 읽는다”의 의미: 여기서 tree를 읽는다는 것은 JSON 안의 section **node**들을 읽고, 각 node가 어떤 부모/자식 관계로 연결되어 있는지 확인한다는 뜻입니다. 즉 **용어의 정의** 같은 section 하나가 node이고, `nodes` 배열 안에 들어 있는 하위 section들이 child node입니다. 따라서 **tree 확인 = node 목록과 node 간 계층 관계 확인**이라고 볼 수 있습니다.

Leaf node와 branch node: leaf node는 더 이상 자식 node가 없는 맨 아래 node입니다. JSON 기준으로는 `"nodes": []` 처럼 하위 배열이 비어 있으면 leaf node입니다. 반대로 **용어의 정의** 처럼 `nodes` 안에 **다. “일탈”**, **라. “기준일탈”** 같은 하위 node를 가진 node는 leaf가 아닌 branch/parent node입니다.

핵심 원칙: retrieve는 항상 맨 아래 leaf node만 읽지 않습니다. 질문 범위에 맞춰 상위 node, 중간 node, leaf node 중 가장 적절한 depth를 선택합니다. 정의처럼 좁은 질문은 leaf node까지 내려가고, 절차·요건·종합 질문은 중간 node와 여러 child node를 함께 확인합니다.

따라서 실제 retrieve 판단은 AI가 질문의 의미를 먼저 해석한 뒤, tree JSON의 `title`, `nodes`, page range, 부모/자식 관계를 보고 어느 깊이까지 내려갈지 결정하는 방식입니다. AI가 곧바로 PDF 전체 본문을 읽는 것이 아니라, 먼저 tree에서 관련 node와 적절한 depth를 고른 다음 그 node의 page range를 근거로 필요한 page만 `get_page_content` 로 확인합니다.

질문 유형	읽는 NODE 깊이	GMP 예시	RETRIEVE 판단
정의 질문	leaf node까지 내려감	“일탈”이란 무엇인가?	용어의 정의 → 다. “일탈” node → p.18
절차/요건 질문	중간 node와 여러 child node 확인	변경관리는 어떻게 수행하는가?	변경관리 node의 subtree p.441-447 범위에서 관련 조항 확인
비교 질문	관련 leaf node 여러 개 확인	일탈과 기준일탈은 어떻게 다른가?	다. “일탈” node와 라. “기준일탈” node를 함께 확인
넓은 관리체계 질문	상위/중간 node의 subtree 범위 확인	품질경영 체계는 무엇을 포함하는가?	품질경영 관련 상위 node와 child node들을 함께 검토

단계	PAGEINDEX TOOL	확인 내용	GMP 예시
1	get_document()	문서명, 타입, 전체 page 수 확인	gmp_guidance.pdf · 606 pages
2	get_document_structure()	본문 전체를 열기 전에 section node, 하위 node, page 범위가 담긴 JSON tree 확인	용어의 정의 node · subtree p.18-28
3	section/page 후보 선택	질문 의미에 맞는 section path와 tight page range 선택	“일탈” 질문 → 용어의 정의 → p.18
4	get_page_content(pages)	선택한 page의 실제 본문 확인	p.18에서 “일탈” 정의 문장 확인
5	prediction 기록	predicted_section_path, predicted_pages, evidence_pages_read 저장	predicted_pages: 18-19


Tree JSON의 핵심 속성: `title` 은 section node의 제목, `nodes` 는 하위 node 배열, `own_start_index/end_index` 는 해당 node 자체의 page 범위, `subtree_start_index/end_index` 는 하위 node까지 포함한 전체 page 범위를 의미합니다. 본문 전체는 이 단계에서 모두 읽지 않고, page 후보가 좁혀진 뒤 `get_page_content` 로 확인합니다.

4. 결과

공식 metric

METRIC	VALUE
Original predicted page hit rate	93.0%
Aligned predicted union hit rate	96.0%
Evidence union hit rate	95.0%
Evidence+aligned hit rate	99.0%
Aligned precision avg	0.3773

Eval 분포



Retrieval classification

CLASSIFICATION	COUNT
already_hit	93
coordinate_shift_in_predicted_pages	3
evidence_read_contains_gold_but_final_page_selection_missed	2
coordinate_shift_in_evidence_pages_read	1
unrecovered	1

5. 해석

Aligned hit rate 도입 배경: GMP PDF는 PDF 물리 page와 문서 내부 page 번호가 밀리는 구간이 있어, 단순 page 번호 비교만으로는 검색 성능이 왜곡될 수 있습니다. 따라서 page alignment map을 반영한 aligned predicted union을 공식 기준으로 사용했습니다.

Evidence+aligned의 의미: 99.0%는 최종 선택 page가 아니라, retriever가 탐색 과정에서 읽은 evidence page 까지 포함한 진단 coverage입니다. 공식 headline은 96.0%로 유지합니다.

Predicted page와 evidence page의 차이

`evidence_pages_read` 는 retriever가 탐색 과정에서 `get_page_content` 로 실제 열어본 후보 page를 의미합니다. 따라서 evidence page에 gold page가 포함되어 있다면 “LLM이 그 page를 전혀 보지 않았다”는 뜻이 아니라, 읽기는 읽었지만 최종 `predicted_pages` 로 채택하지 않았을 수 있다는 뜻입니다.

필드	의미	평가상 해석
<code>predicted_pages</code>	최종적으로 정답 근거 page라고 제출한 page	공식 hit rate의 핵심 기준
<code>evidence_pages_read</code>	탐색 중 실제로 열어본 후보 page	LLM이 탐색 과정에서 본 page 기록
<code>evidence_plus_aligned</code>	evidence page와 page alignment 보정을 함께 본 진단 범위	최종 선택은 틀렸지만 근거 page 근처를 읽었는지 확인

해석 예시: gold page가 p.533인데 `predicted_pages` 가 p.519-521이고 `evidence_pages_read` 에 p.533이 포함되어 있다면, 이는 “LLM context에 들어가지 않았다”가 아니라 “탐색 중 p.533을 봤지만 최종 page selection 에서 p.533을 선택하지 못했다”로 해석합니다.

자연어 답변 관점의 진단

현재 산출물에는 별도의 `final_answer` 필드가 없습니다. 따라서 엄밀하게는 “최종 자연어 답변”과 평가셋의 `expected_answer` 를 직접 비교할 수 없습니다. 다만 각 prediction에는 retrieval 판단 이유인 `reason` 이 있으므로, 이를 자연어 답변 후보처럼 보아 보조적으로 의미 유사성을 점검했습니다.

ID	상황	REASON VS EXPECTED_ANSWER	해석
gmp_eval_013	evidence_plus_aligned는 hit, 최종 predicted page는 miss	낮음	근거 page 근처를 봤지만 reason도 정답 핵심 문구를 충분히 담지 못함
gmp_eval_084	evidence에서 gold page를 읽었지만 최종 page 선택 실패	높음	자연어 이해는 expected_answer와 매우 유사하나 최종 page selection이 실패
gmp_eval_086	evidence에서 gold page를 읽었지만 최종 page 선택 실패	중간~높음	핵심 취지는 맞지만 설명 범위가 넓고 약간 분산됨

주의: 이 표는 answer generation 정식 평가는 아닙니다. 현재 eval은 자연어 답변 품질이 아니라 근거 page retrieval 평가입니다. 따라서 위 결과는 `reason` 을 임시 자연어 후보로 본 진단이며, 실제 최종 답변 생성에 해당 evidence가 사용되었는지는 별도 `final_answer` 로그와 answer judging이 있어야 판단할 수 있습니다.

잔여 오류는 크게 두 유형으로 나뉩니다. 첫째, 근거 page를 읽었지만 최종 page selection에서 놓친 사례입니다. 둘째, evidence 탐색 과정에서도 gold page를 찾지 못한 더 강한 실패입니다. 현재 완전 미회수 사례는 `gmp_eval_025` 1건입니다.

6. 한계

- 평가셋은 100개 문항으로 구성되어 있어, 더 넓은 GMP 질의 유형을 모두 대표한다고 보기는 어렵습니다.
- Evidence+aligned는 내부 탐색 coverage를 보여주는 진단 지표이며, 최종 사용자에게 반환되는 page 선택 성능과 동일하지 않습니다.
- Tree 구조는 현재 PDF와 산출물 기준으로 검증되었으며, 다른 개정본 PDF에는 page alignment와 tree boundary를 다시 확인해야 합니다.

7. 다음 단계

- 실패 4건 상세 분석:** aligned miss 4건의 원인을 page selection, evidence 탐색, semantic confusion으로 분류합니다.
- 평가셋 확장:** 100개에서 더 다양한 장/절/질문 유형으로 확장합니다.
- 보고서 배포:** 본 HTML을 브라우저 print/PDF로 내보내 외부 공유용 PDF를 생성합니다.

8. 재현 가능한 산출물

본 보고서는 아래 repository artifact를 기준으로 재생성할 수 있습니다.


ARTIFACT	역할
results/pageindex_gmp_workspace/gmp-guidance.json	PageIndex workspace
results/gmp_guidance_structure.json	최종 tree JSON
results/visualizations/gmp_guidance_tree.txt	ASCII tree 원본
eval/gmp_eval_testset.jsonl	100개 평가셋
results/codex_agentic_10x10/predictions_001_100_agentic.jsonl	검색 예측 결과
results/page_alignment/score_001_100_agentic_official_alignment.json	최종 official score
scripts/gmp_build_final_report.py	single-file HTML 생성 스크립트

부록 A. Tree 요약

전체 tree를 긴 표로만 보지 않도록, 최상위 branch의 문서 범위와 node 밀도를 먼저 보여줍니다. 아래 막대는 각 branch가 차지하는 page span을 기준으로 상대 크기를 표현합니다.

Document map: page span × tree depth

가로축은 PDF page 범위, 세로축은 tree depth입니다. 넓은 사각형일수록 해당 section subtree가 문서에서 차지하는 page span이 크다는 뜻입니다.



Tree explorer: collapsible section outline

ASCII 대신 section 제목을 직접 접고 펼쳐 볼 수 있는 탐색용 outline입니다. 화면에서는 전체 641개 node를 확인할 수 있고, PDF에서는 깊은 하위 레벨을 접어 레이아웃을 보호합니다.

nodes 641 max depth 6 top branches 5

Preface D0 p.1-9 own p.1-9

▼ 제1장 서론 D0 p.9-16 2 children own p.9-10

목적 및 원칙 D1 p.10-12 own p.10-12

구성방법 D1 p.12-16 own p.12-16

▼ 제2장 완제의약품 제조 및 품질관리기준 D0 p.16-478 16 children own p.16-18

▼ 용어의 정의 D1 p.18-28 37 children own p.18

가. “관리번호”란 제조단위를 부여할 수 없는 자재 등을 관리하기 위하여 부여한 번호로서 숫자 · 문자 또는 이들을 조합한 것을 말한다. D2 p.18 own p.18

나. “교정”이란 계측기, 시험기기 또는 기록계가 나타내는 값과 표준기기 의 참값을 비교하여 오차가 허용범위 내에 있음을 확인하고, 허용오 차범위를 벗어나는 경우 허용범위 내에 들도록 조정하는 것을 말한다. D2 p.18 own p.18


다. “일탈”이란 제조 또는 품질관리 과정에서 미리 정해진 기준을 벗어나 이루어진 행위를 말한다.

D2 p.18 own p.18

Tree at a glance

Preface


depth 0 · 1 nodes



p.1-9
9 pages · density 0%

제1장 서론

depth 1 · 3 nodes



p.9-16
8 pages · density 1%

제2장 완제의약품 제조 및 품질 관리기준


depth 6 · 531 nodes



p.16-478
463 pages · density 100%

별첨1 의약품 제조소의 시설


depth 2 · 83 nodes



p.478-554
77 pages · density 16%

별첨2 컴퓨터화 시스템

depth 2 · 23 nodes



p.554-606
53 pages · density 4%

depth 0

5

depth 1

25

depth 2

213

depth 3

318

depth 4

62

depth 5

14

depth 6

4

TOP BRANCH	NODES	MAX DEPTH	OWN PAGES	SUBTREE PAGES
Preface	1	0	1-9	1-9
제1장 서론	3	1	9-10	9-16
제2장 완제의약품 제조 및 품질관리기준	531	6	16-18	16-478
별첨1 의약품 제조소의 시설	83	2	478-482	478-554
별첨2 컴퓨터화 시스템	23	2	554-559	554-606

Technical ASCII tree

- Preface [1-9] #0000
- 제1장 서론 [9-16] own[9-10] #0001
 - 목적 및 원칙 [10-12] #0002
 - 구성방법 [12-16] #0003
- 제2장 완제의약품 제조 및 품질관리기준 [16-478] own[16-18] #0004
 - 용어의 정의 [18-28] own[18-18] #0005
 - 가. “관리번호”란 제조단위를 부여할 수 없는 자재 등을 관리하기 위하여 부여한 번호로서 숫자·문자 또는 이들을 조합한 것을 말한다. [18-18] #0006
 - 나. “교정”이란 계측기, 시험기가 또는 기록계가 나타내는 값과 표준기의 참값을 비교하여 오차가 허용범위 내에 있음을 확인하고, 허용오차범위를 벗어나는
 - 다. “일탈”이란 제조 또는 품질관리 과정에서 미리 정해진 기준을 벗어나 이루어진 행위를 말한다. [18-18] #0008
 - 라. “기준일탈”이란 시험의 결과가 미리 정하여진 시험기준을 벗어난 경우를 말한다. [18-18] #0009
 - 마. “무균구역”이란 무균작업을 위한 무균물질 또는 멸균처리된 용기가 노출되는 장소, 무균제제를 채워 넣거나 밀봉하는 작업을 하는 장소 및 무균시험 등의 무
 - 바. “반제품”이란 제조과정 단계에 있는 것으로서 필요한 제조공정을 더 거쳐야 완제품이 되는 것을 말한다. [18-18] #0011
 - 해설 [18-18] #0012
 - 참고자료 유럽 GMP EudraLex 4 Part I [18-18] #0013
 - 참고자료 캐나다 GUI-0001 [18-18] #0014
 - 사. “밸리데이션”이란 특정한 공정, 방법, 기계설비 또는 시스템이 미리 설정 되어 있는 판정기준에 맞는 결과를 일관되게 도출한다는 것을 검증하고 이를 문서화
 - 아. “수율”이란 이론 생산량에 대한 실생산량의 백분율을 말한다. [18-18] #0016
 - 자. “수율관리기준”이란 제조공정이 정상적으로 진행되었을 경우 얻어지는 제품별 연간 평균생산수율 범위를 말한다. [18-18] #0017
 - 차. “실생산량”이란 제조공정에서 실제로 얻은 양을 말한다. [18-18] #0018
 - 카. “완제의약품”이란 모든 제조공정이 완료되어 최종적으로 인체에 투여할 수 있도록 일정한 제형으로 제조된 의약품을 말한다. [18-18] #0019
 - 타. “완제품”이란 의약품 제조에서 모든 제조공정이 완료된 원료의약품 또는 완제의약품을 말한다. [18-18] #0020
 - 파. “원료약품”이란 완제품의 제조에 사용되는 물질(자재는 제외한다)을 말하며, 완제품에 남아 있지 않은 물질을 포함한다. [18-18] #0021
 - 하. “원료의약품”이란 합성, 발효, 추출 등 또는 이 방법들의 조합에 의하여 제조된 물질로서 완제의약품의 제조에 사용되는 것을 말한다. [18-18] #0022
 - 거. “원생약”이란 동물, 식물 또는 광물에서 채취된 것으로서 한약원료로 사용하기 위한 세척·선별·절단 등 가공을 하지 않은 상태의 것을 말한다. [18-18]
 - 너. “원자재”란 원료약품 및 자재를 말한다. [18-18] #0024
 - 더. “이론 생산량”이란 원료약품의 투입량으로부터 이론적으로 계산된 반제품 또는 완제품의 양을 말한다. [18-18] #0025

부록 B. Eval 100문항 브라우저 및 실패 사례

100개 문항을 모두 본문에 펼치면 인쇄 레이아웃이 깨지므로, 화면에서는 토크/필터로 전체 문항을 확인하고 PDF에서는 요약 표와 실패 사례 중심으로 읽을 수 있게 구성했습니다.

100 / 100개 문항 표시

행을 클릭하면 아래 상세 근거가 바뀝니다.

ID	DIFF	HIT	GOLD	QUESTION
gmp_eval_001	easy	aligned hit	18	GMP 기준에서 '일탈'은 무엇을 의미하는가?
gmp_eval_002	easy	aligned hit	18	'기준일탈'의 정의는 무엇인가?
gmp_eval_003	easy	aligned hit	21	이 기준에서 '밸리데이션'은 어떻게 정의되는가?
gmp_eval_004	easy	aligned hit	559	GMP 기준에서 '컴퓨터화 시스템(computerized system)'은 어떻게 정의되는가?
gmp_eval_005	easy	aligned hit	21	'재가공'의 정의는 무엇인가?
gmp_eval_006	easy	aligned hit	602	컴퓨터화 시스템 관리에서 '시스템 책임자(System owner)'는 무엇을 책임지는 사람인가?
gmp_eval_007	easy	aligned hit	24	'청정구역'이란 무엇을 관리하는 구역인가?
gmp_eval_008	easy	aligned hit	602	컴퓨터화 시스템 관리에서 '전주기(Life cycle)'란 무엇을 의미하는가?
gmp_eval_009	medium	aligned hit	18	'무균구역'은 어떤 장소들을 말하는가?
gmp_eval_010	medium	aligned hit	270	세척 밸리데이션은 무엇을 검증·문서화하는 밸리데이션인가?
gmp_eval_011	easy	aligned hit	54	작업소의 기계·설비는 어떤 기준에 따라 배치하여야 하는가?
gmp_eval_012	easy	aligned hit	62	의약품 제조에 사용하는 제조용수는 어떤 점이 확보되도록 관리하여야 하는가?
gmp_eval_013	easy	evidence only	533	원료 칭량·조제·충전·밀봉 작업실의 천장과 바닥·벽은 어떤 기준을 갖추어야 하는가?
gmp_eval_014	easy	aligned hit	67	작업소의 하수구가 갖추어야 할 두 가지 요구사항은 무엇인가?
gmp_eval_015	easy	aligned hit	81	작업소의 청정구역과 청정등급은 어떻게 설정하고 유지·점검하여야 하는가?
gmp_eval_016	medium	aligned hit	82	공기조화장치의 성능과 작업실 간 차압은 어떻게 점검·유지하여야 하는가?
gmp_eval_017	easy	aligned hit	78	제조·품질관리에 자동화장치 등을 사용할 경우 요구되는 관리사항은?
gmp_eval_018	easy	aligned hit	235	기록문서 작성 방식에 대한 요구사항은 무엇인가?
gmp_eval_019	easy	aligned hit	392	작업원은 작업복 등을 어떤 기준에 따라 착용하여야 하는가?

ID	DIFF	HIT	GOLD	QUESTION
gmp_eval_020	easy	aligned hit	423	원자재 및 완제품의 보관·출고 방식에 대한 요구사항은?

gmp_eval_001 · GMP 기준에서 '일탈'은 무엇을 의미하는가?

Gold 18

Pred 18-19

Aligned hit hit

Difficulty easy

Aligned 25-26

Evidence+aligned hit

Gold section: 제2장 완제의약품 제조 및 품질관리기준 > 용어의 정의

Predicted section: 제2장 완제의약품 제조 및 품질관리기준 > 용어의 정의 > 다. "일탈"

Evidence pages read: 18-19 / **Evidence+aligned:** 18-19,25-26

Expected answer: 제조 또는 품질관리 과정에서 미리 정해진 기준을 벗어나 이루어진 행위를 말한다.

Gold evidence summary: 용어의 정의 조항에 '다. 일탈'의 정의가 그대로 기재되어 있다.

Retriever reason: 정의성 질문이라 용어의 정의를 우선 확인했고, page 18의 기준 다 및 page 19 해설이 일탈을 제조 또는 품질관리 과정에서 미리 정해진 기준을 벗어난 행위로 설명한다.

주요 실패/보정 사례

ID	CLASSIFICATION	GOLD	PREDICTED	EVIDENCE+ALIGNED
gmp_eval_013	coordinate_shift_in_evidence_pages_read	533	519-521	500,507,519-521,526-528,533-535
gmp_eval_025	unrecovered	401	81	81-84,88-91
gmp_eval_032	coordinate_shift_in_predicted_pages	415	408-410	408-421
gmp_eval_042	coordinate_shift_in_predicted_pages	252	245	245,252
gmp_eval_072	coordinate_shift_in_predicted_pages	535	500,516-522,528-530	500,507,516-530,533-537
gmp_eval_084	evidence_read_contains_gold_but_final_page_selection_missed	249	256-260	249-273
gmp_eval_086	evidence_read_contains_gold_but_final_page_selection_missed	408	290-291	290-292,297-299,408-410,415-417

평가 문항 예시

ID	DIFFICULTY	ALIGNMENT	GOLD	QUESTION
gmp_eval_001	easy	hit	18	GMP 기준에서 '일탈'은 무엇을 의미하는가?
gmp_eval_002	easy	hit	18	'기준일탈'의 정의는 무엇인가?
gmp_eval_003	easy	hit	21	이 기준에서 '밸리데이션'은 어떻게 정의되는가?
gmp_eval_004	easy	hit	559	GMP 기준에서 '컴퓨터화 시스템(computerized system)'은 어떻게 정의되는가?
gmp_eval_005	easy	hit	21	'재가공'의 정의는 무엇인가?
gmp_eval_006	easy	hit	602	컴퓨터화 시스템 관리에서 '시스템 책임자(System owner)'는 무엇을 책임지는 사람인가?
gmp_eval_007	easy	hit	24	'청정구역'이란 무엇을 관리하는 구역인가?
gmp_eval_008	easy	hit	602	컴퓨터화 시스템 관리에서 '전주기(Life cycle)'란 무엇을 의미하는가?
gmp_eval_025	medium	miss	401	작업소의 청정구역은 청정도를 어떻게 관리하여야 하는가?